

Proyecto#1

María José Ramírez Cifuentes, Daniel Machic y Javier Chen

2025-07-14

ANÁLISIS EXPLORATORIO PROYECTO #1

A continuación se presentará un análisis exploratorio para el dataset “establecimientos.csv”, el cual contempla establecimientos educativos del departamento de Guatemala específicamente en el municipio de Mixco.

LECTURA DEL ARCHIVO

```
library(dplyr)
```

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union
```

```
library(stringr)
library(readr)
```

```
datos <- read.csv("C:/Users/ram22/Downloads/Proyecto1-Data Science/establecimiento.csv",
                  fileEncoding = "Latin1",
                  stringsAsFactors = FALSE)
```

```
head(datos)
```

```
##           CODIGO X DISTRITO DEPARTAMENTO MUNICIPIO
## 1 01-08-0001-45 NA    01-603    GUATEMALA    MIXCO
## 2 01-08-0002-42 NA    01-609    GUATEMALA    MIXCO
## 3 01-08-0003-43 NA    01-609    GUATEMALA    MIXCO
## 4 01-08-0005-45 NA    01-609    GUATEMALA    MIXCO
## 5 01-08-0006-46 NA    01-609    GUATEMALA    MIXCO
## 6 01-08-0007-43 NA    01-602    GUATEMALA    MIXCO
##
## ESTABLECIMIENTO
```

```

## 1          COLEGIO CRISTIANO ELIM
## 2 COLEGIO NEOZELANDES SAN CRISTOBAL
## 3 COLEGIO NEOZELANDES SAN CRISTOBAL
## 4 COLEGIO NEOZELANDES SAN CRISTOBAL
## 5 COLEGIO NEOZELANDES SAN CRISTOBAL
## 6 COLEGIO MIXTO LA FUENTE DE SILOE
##
##                                DIRECCION TELEFONO
## 1          3A. AVENIDA 11-42 ZONA 3, COLONIA EL ROSARIO 24370113
## 2 2A. CALLE 9-98 SECCION A-1 COLONIAS LAS ORQUIDEAS 24784553
## 3 2A. CALLE 9-98 SECCION A-1 COLONIA LAS ORQUIDEAS 24784553
## 4 2A CALLE 9-98 SECCION A-1 COLONIA LAS ORQUIDEAS 24784553
## 5 2A. CALLE 9-98 SECCION A-1 COLONIA LAS ORQUIDEAS 24784553
## 6 7A. CALLE 10-57 LO DE FUENTES ZONA 11 DE MIXCO 58232801
##
##                                SUPERVISOR                                DIRECTOR
## 1          ROSA ALBELIA ARDON DE MOTTA MARIA DEL CARMEN GONZÁLEZ ALVAREZ
## 2          SILVIA HORTENSIA GONZALEZ MARTINEZ          ELIZA CAROLINA JIMÉNEZ ZAVALA
## 3          SILVIA HORTENSIA GONZALEZ MARTINEZ          MADY LUZ LÓPEZ ALVARADO
## 4          SILVIA HORTENSIA GONZALEZ MARTINEZ          ELIZA CAROLINA JIMÉNEZ ZAVALA
## 5          SILVIA HORTENSIA GONZALEZ MARTINEZ          ELIZA CAROLINA JIMÉNEZ ZAVALA
## 6 IDALIA DEL ROSARIO LOPEZ SANDOVAL DE PAIZ          MARIA IRENE BAUTISTA CARACUN
##
##      NIVEL  SECTOR  AREA  STATUS  MODALIDAD  JORNADA      PLAN
## 1          BASICO PRIVADO URBANA ABIERTA MONOLINGUE  DOBLE  FIN DE SEMANA
## 2          PARVULOS PRIVADO URBANA ABIERTA MONOLINGUE MATUTINA DIARIO(REGULAR)
## 3          PRIMARIA PRIVADO URBANA ABIERTA MONOLINGUE MATUTINA DIARIO(REGULAR)
## 4          BASICO PRIVADO URBANA ABIERTA MONOLINGUE MATUTINA DIARIO(REGULAR)
## 5 DIVERSIFICADO PRIVADO URBANA ABIERTA MONOLINGUE MATUTINA DIARIO(REGULAR)
## 6          PRIMARIA PRIVADO URBANA ABIERTA MONOLINGUE MATUTINA DIARIO(REGULAR)
##
##      DEPARTAMENTAL X.1 X.2
## 1 GUATEMALA OCCIDENTE  NA
## 2 GUATEMALA OCCIDENTE  NA
## 3 GUATEMALA OCCIDENTE  NA
## 4 GUATEMALA OCCIDENTE  NA
## 5 GUATEMALA OCCIDENTE  NA
## 6 GUATEMALA OCCIDENTE  NA

```

NÚMEROS DE DATOS Y VARIABLES

```

# Descripción general
cat("El dataset tiene un total de: ", nrow(datos), "filas y", ncol(datos), "columnas.\n")

```

```

## El dataset tiene un total de: 1437 filas y 20 columnas.

```

```

# Nombres de las variables
colnames(datos)

```

```

## [1] "CODIGO"          "X"               "DISTRITO"        "DEPARTAMENTO"
## [5] "MUNICIPIO"       "ESTABLECIMIENTO" "DIRECCION"        "TELEFONO"
## [9] "SUPERVISOR"      "DIRECTOR"        "NIVEL"            "SECTOR"
## [13] "AREA"            "STATUS"          "MODALIDAD"        "JORNADA"
## [17] "PLAN"            "DEPARTAMENTAL"  "X.1"              "X.2"

```

El conjunto de datos cuenta con un total de 1,437 filas y 20 variables. Entre las columnas se incluyen identificadores como CODIGO y X, así como información geográfica (DISTRITO, DEPARTAMENTO, MUNICIPIO) y administrativa (ESTABLECIMIENTO, DIRECCION, TELEFONO, SUPERVISOR, DIRECTOR). También se presentan variables relacionadas con características operativas de los establecimientos, tales como NIVEL, SECTOR, AREA, STATUS, MODALIDAD, JORNADA, y PLAN. Finalmente, se observan columnas adicionales como DEPARTAMENTAL, X.1 y X.2, que podrían requerir un análisis más detallado para determinar su relevancia o necesidad de limpieza.

IDENTIFICACIÓN VARIABLES QUE REQUIEREN LIMPIEZA

```
# Identificar variables de texto y numéricas
texto_vars <- names(datos)[sapply(datos, is.character)]
num_vars <- names(datos)[sapply(datos, is.numeric)]

cat("Variables de texto que podrían requerir limpieza:\n")
```

```
## Variables de texto que podrían requerir limpieza:
```

```
print(texto_vars)
```

```
## [1] "CODIGO"          "DISTRITO"         "DEPARTAMENTO"      "MUNICIPIO"
## [5] "ESTABLECIMIENTO" "DIRECCION"        "TELEFONO"         "SUPERVISOR"
## [9] "DIRECTOR"        "NIVEL"            "SECTOR"           "AREA"
## [13] "STATUS"          "MODALIDAD"        "JORNADA"          "PLAN"
## [17] "DEPARTAMENTAL"   "X.2"
```

```
cat("\nVariables numéricas:\n")
```

```
##
## Variables numéricas:
```

```
print(num_vars)
```

```
## character(0)
```

El subconjunto de datos visualizado contiene 6 filas y 20 columnas, correspondientes a establecimientos educativos. Entre las variables presentes, se identifican campos alfanuméricos como CODIGO, DISTRITO, DEPARTAMENTO, MUNICIPIO, ESTABLECIMIENTO, DIRECCION, y TELEFONO, que contienen información administrativa y de localización. También se incluyen otras variables descriptivas como SUPERVISOR, DIRECTOR, NIVEL, SECTOR, AREA, STATUS, MODALIDAD, JORNADA, PLAN, y DEPARTAMENTAL. Cabe destacar que la mayoría de las variables son de tipo texto, mientras que no se identifican variables estrictamente numéricas en este conjunto. Las variables ESTABLECIMIENTO, DIRECCION y TELEFONO son candidatas principales para limpieza debido a posibles inconsistencias en el formato, uso de mayúsculas/minúsculas, presencia de caracteres especiales o duplicados que podrían afectar futuros análisis.

Estrategia para limpieza del conjunto de datos

1. CODIGO

- Verificar que todos tengan el formato correcto (ejemplo: NN-NNN-NNNN-NN).
- Detectar y eliminar duplicados exactos (no debe haber códigos repetidos).
- Validar que no haya códigos vacíos o con caracteres inválidos.

2. DISTRITO

- Corregir formato: asegurarse que tenga un código numérico de 6 caracteres, sin espacios.
- Completar valores vacíos si es posible, usando otras columnas (ejemplo: 01-603 para Mixco).
- Eliminar duplicados si los hay.

3. DEPARTAMENTO

- Uniformizar mayúsculas (ej. todo en mayúsculas).
- Corregir errores ortográficos, respetando la escritura oficial (ej. GUATEMALA, SACATEPEQUEZ).
- Completar valores vacíos según código de distrito o municipio.

4. MUNICIPIO

- Uniformizar mayúsculas.
- Verificar que corresponda al departamento.
- Corregir errores ortográficos respetando nombres oficiales.

5. ESTABLECIMIENTO

- Mantener la escritura original (sin cambiar mayúsculas/minúsculas ni abreviaciones oficiales).
- Revisar posibles duplicados por error (ej. dos filas con el mismo establecimiento pero diferente código).
- Corregir errores ortográficos sutiles solo si son obvios y confirmados (consultar con fuente si es posible).

6. DIRECCION

- Establecer formato uniforme para las direcciones (por ejemplo, separar calles, números, zonas con comas).
- Corregir errores ortográficos comunes (ej. “CALLE” en vez de “CALLEE”).
- Limpiar espacios dobles o caracteres especiales innecesarios.

7. TELEFONO

- Uniformizar formato: solo números sin espacios, guiones o paréntesis.
- Validar longitud correcta (ej. números con 8 dígitos para Guatemala).
- Revisar valores vacíos o erróneos.

8. SUPERVISOR y DIRECTOR

- Mantener nombres completos con mayúsculas en iniciales.
- Corregir errores ortográficos o de acentos si son evidentes.
- Eliminar espacios dobles.

9. NIVEL

- Uniformizar categorías (ej. BASICO, PRIMARIA, DIVERSIFICADO).
- Corregir posibles errores tipográficos.

10. SECTOR

- Uniformizar a PRIVADO, PUBLICO, etc.
- Corregir errores.

11. AREA

- Uniformizar a URBANA, RURAL, etc.
- Corregir errores.

12. STATUS

- Uniformizar a ABIERTA, CERRADA, etc.

13. MODALIDAD

- Uniformizar categorías (ej. MONOLINGUE, BILINGUE, etc.)

14. JORNADA

- Uniformizar categorías (ej. MATUTINA, VESPERTINA, DOBLE).
- Corregir errores.

15. PLAN

- Uniformizar etiquetas (ej. FIN DE SEMANA, DIARIO (REGULAR)).
- Corregir errores.

16. DEPARTAMENTAL

- Mantener texto original, uniformizando mayúsculas.
- Corregir errores ortográficos si hay.

Consideraciones generales

- No eliminar filas a menos que estén completamente vacías o claramente erróneas.
- No cambiar nombres oficiales sin confirmación.
- Usar scripts de limpieza con paquetes como `dplyr`, `stringr` en R para automatizar las correcciones.
- Documentar todos los pasos de limpieza para reproducibilidad y transparencia.